

系统输入：

记忆与推理分离、分层的通用大模型。设计记忆与推理分离、分层的通用大模型新架构，构建推理数据集，研究大模型的基础理论及训练方法。具体包括：1) 探索记忆与推理分离的模型架构，实现可扩展、可学习、高压缩、分布式、分层的记忆存储，设计存算高效的新型训练方法，通过从头预训练大模型（不少于7B参数，1T Tokens）验证新架构与新训练方法的有效性；2) 实现文本推理数据的自动提取，自动构建自然语言推理数据和形式化数学定理数据库；3) 阐明Next-Token Prediction训练范式有效性的内在机制，研究超参数和模型复杂度等对大模型推理能力的影响。

系统输出：

科学发现提案：

Cogni-Stratum：记忆-推理正交解耦的分层通用大模型

1. 研究背景与意义

1.1 “参数纠缠”的认知瓶颈

当前主流的大语言模型（LLM）采用“单体稠密架构”，将事实性知识（记忆）与逻辑推演能力（推理）混杂在同一套 Transformer 参数中。这种耦合导致了显著的“灾难性遗忘”和“幻觉”问题：更新知识往往破坏推理能力，而强行增强推理又可能导致事实扭曲。现有模型在处理长链条推理时，往往因显存被非必要的记忆性参数占据而导致上下文窗口溢出。

1.2 迈向“双系统”AI 范式

受认知神经科学中“海马体（情景记忆）”与“前额叶（执行推理）”分离机制的启发，本研究旨在重构大模型的基础形态。我们提出构建一种 **分层解耦架构**，将“世界知识库”从计算图的主干中剥离，使其成为可独立更新、高度压缩的外部化神经存储，从而释放核心参数以专注于纯粹的逻辑运算。

核心隐喻：“现有的 LLM 就像一个试图把整个图书馆的书都背下来的学生，而我们试图打造一个随时手持图书馆目录（高效记忆）的顶尖数学家（极致推理）。”

2. 核心科学问题与假设

2.1 记忆-推理正交性假设 (M-R Orthogonality)

H_0 : 存在一种参数空间划分 $\Phi = \{\theta_{\text{mem}}, \theta_{\text{reason}}\}$, 使得模型在纯推理任务 R 上的损失函数 L_{reason} 满足:

$$|\partial(L_{\text{reason}}) / \partial(\theta_{\text{mem}})| < \epsilon$$

这意味着更新记忆模块参数几乎不影响推理核心的稳定性, 且推理能力的 Scaling Law 增长率将不再受限于记忆参数的饱和。

2.2 NTP 的算法压缩机制

针对 Next-Token Prediction (NTP) 范式, 我们假设: NTP 的有效性源于其隐式地最小化了训练数据的柯尔莫哥洛夫复杂性 (Kolmogorov Complexity)。

$$\min K(\text{Data} | \text{Model}) \approx \min \sum -\log P(\text{token}_t | \text{context})$$

当模型结构支持解耦时, NTP 会自动将高频共现模式 (知识) 路由至 θ_{mem} , 而将抽象的算法转换规则 (推理) 路由至 θ_{reason} 。

3. 研究计划与技术路线

3.1 第一阶段: 解耦架构设计与基座预训练 (第 1-12 个月)

任务: 实现可扩展、可学习、分布式的记忆分离架构。

架构蓝图 (Differentiated-Transformer):

- μ -Layer (记忆层):** 采用高压缩比的 Product Quantization (PQ) 键值对存储, 支持分布式热插拔。
- ρ -Core (推理核):** 纯粹的注意力计算单元, 剥离 FFN 中的知识存储功能, 专注于 Token 间的因果操作。

验证实验:

- 规模:** 从头预训练 **7B 参数** 模型。
- 数据量:** 清洗并训练不少于 **1T Tokens** 的高质量语料。
- 存算优化:** 设计 **Gradient-Routing (梯度路由)** 算法, 在反向传播时根据 Token 的“信息熵类型”自动分流梯度更新。

3.2 第二阶段：推理数据工厂与形式化证明 (第 13-24 个月)

任务：自动构建高纯度推理数据集。

数据构建流程：

```
class LogicDistiller:
    def __init__(self):
        self.lean_parser = FormalMathExtractor() # 形式化数学提取
        self.nlp_converter = TextToLogicGraph() # 文本转逻辑图

    def build_dataset(self, raw_corpus):
        # 1. 提取自然语言推理 (NLI)
        logic_chains = self.nlp_converter.extract_implications(raw_corpus)

        # 2. 构建形式化数学定理库
        theorems = self.lean_parser.verify_and_generate(
            source="arXiv_math",
            target_format="Isabelle/Lean"
        )

        return MixedReasoningBatch(logic_chains, theorems)
```

交付物：

- **LogicNet-100B**：包含 1000 亿 token 的纯逻辑推演与代码执行数据。
- **Formal-Math-DB**：对齐自然语言与 Lean4 代码的定理证明数据库。

3.3 第三阶段：理论机制解析与超参研究 (第 25-36 个月)

研究重点：

1. **NTP 机制解析**：通过“信息瓶颈理论 (Information Bottleneck)”量化 NTP 训练过程中互信息 $I(X; T)$ 的变化，证明解耦架构能更早进入“相变”区域。
2. **超参数敏感性分析**：
 - 探究 **记忆容量 vs. 推理深度** 的最优比率 (Capacity-Depth Ratio)。
 - 研究模型复杂度 (Model Complexity) 对零样本推理 (Zero-shot Reasoning) 准确率的非线性影响。

4. 预期成果与影响

4.1 科学交付成果

- 模型原型**: **SepLLM-7B**, 首个经 1T Tokens 验证的记忆推理分离通用模型, 显存占用降低 40%, 推理速度提升 2.5 倍。
- 核心数据集**: 开源全球最大的 **Auto-Reasoning Corpus**, 包含百万级形式化数学证明对。
- 理论白皮书**: 《大模型推理能力的熵减机制与解耦缩放定律》。

4.2 产业与社会价值

- 端侧部署**: 得益于记忆层的分布式特性, 支持在手机端仅加载“推理核”和“特定领域记忆包”, 实现 **On-Device AI** 的模块化。
- 可信 AI**: 通过直接修改记忆层参数即可实时修正错误知识, 无需重新训练, 彻底解决 **知识更新滞后** 问题。

5. 图表与附录

图 1: Cogni-Stratum 双流梯度路由架构示意图

图 2: 解耦模型与传统 Transformer 在 MATH 数据集上的 Loss 下降曲线对比

附录:

A) 梯度路由算法的收敛性证明摘要

B) 形式化定理数据库的数据样张

C) 7B 模型预训练的硬件资源估算表