

系统输入：

记忆与推理分离、分层的通用大模型。设计记忆与推理分离、分层的通用大模型新架构，构建推理数据集，研究大模型的基础理论及训练方法。具体包括：1) 探索记忆与推理分离的模型架构，实现可扩展、可学习、高压缩、分布式、分层的记忆存储，设计存算高效的新型训练方法，通过从头预训练大模型（不少于7B参数，1T Tokens）验证新架构与新训练方法的有效性；2) 实现文本推理数据的自动提取，自动构建自然语言推理数据和形式化数学定理数据库；3) 阐明Next-Token Prediction训练范式有效性的内在机制，研究超参数和模型复杂度等对大模型推理能力的影响。

系统输出：

项目提案：记忆与推理分离分层的通用大模型新架构

1. 研究背景与意义

- **当前痛点：**当前通用大模型（LLM）将记忆与推理功能耦合于同一参数空间。
 - **问题1：**导致知识更新困难，存在灾难性遗忘与事实冲突。
 - **问题2：**推理过程受记忆污染，难以保证逻辑的纯粹性与可解释性。
- **战略意义：**实现认知能力的解耦与分层，是迈向更高阶、更可靠人工智能的关键一步。
 - **架构革新：**为模型提供可扩展、可编辑、高压缩的知识底座。
 - **理论突破：**有望从根本上解释当前预训练范式的有效性与局限性。

2. 核心科学问题与假设

本项目旨在通过架构分离，实现大模型记忆的独立存储与高效推理。核心假设如下：

- **假设1：记忆与推理可解耦。**模型性能可由一个可学习的、高压缩的记忆模块和一个专注逻辑运算的推理引擎协同实现，且效果优于一体化架构。
- **假设2：推理能力可数据驱动。**通过自动化构建大规模、高质量的形式化推理数据，可系统性地“教会”模型进行严谨推理，超越传统文本预测。

- **假设3：训练机制可解释。**模型的推理能力涌现，与Next-Token Prediction目标、超参数配置及模型复杂度之间存在可量化的内在联系。

3. 研究方案与技术路线

为验证上述假设，设计三路并行的研究方案：

3.1 新架构设计与验证

- **架构设计：**构建“记忆库(Memory Bank) + 推理器(Reasoner)”的分离式模型。
 - **记忆库：**实现为可分布式存储、支持高效检索与增量更新的键值网络。
 - **推理器：**设计为参数化、轻量化的计算模块，专注逻辑与抽象操作。
- **训练方法：**研究针对该架构的**新型预训练与微调策略**，解决二者协同训练的优化难题。
- **规模验证：**通过从头预训练一个 **≥7B参数、1T Tokens** 的模型，实证新架构在效能与成本上的优势。

3.2 推理数据自动化构建

- **文本推理提取：**开发自动化流程，从高质量文本（如教科书、学术论文）中提取因果链、假设、证据等，构建**自然语言推理数据集**。
- **形式化数学库构建：**将数学定理及其证明过程（如Lean, Coq格式）转换为模型可学习的形式化序列，构建**机器可验证的定理数据库**。

3.3 大模型基础理论研究

- **Next-Token机制剖析：**通过控制实验，分析该目标函数如何隐式地驱动逻辑与知识学习。
- **能力影响因子建模：**系统研究**模型规模、训练数据分布、超参数**等对最终推理能力的定量影响规律。

4. 预期成果与科学影响

- **直接产出：**
 - 一个开源的、记忆与推理分离的**7B+大模型**与新架构代码。
 - 一套高质量的**公开推理数据集**（文本与形式化数学）。
 - 一系列揭示预训练机制的理论分析论文。
- **长远影响：**
 - **技术路径：**为构建**可终身学习、知识可溯源、推理可审核**的新一代AI系统提供基础架构。

- **行业赋能：** 高效、低成本的记忆更新机制，将极大降低大模型在垂直领域（如法律、医疗）的部署与维护门槛。
- **科学认知：** 深化对“学习”与“推理”这两个智能核心要素的计算理论理解。